

# Тест по прошлой лекции



Санкт-Петербургский  
государственный  
университет



<https://forms.gle/KdJPwNywTgjiion89>







# Сложность алгоритмов



## Асимптотический анализ

Направление «Искусственный интеллект и наука о данных», 23.Б16-мм, 23.Б18-мм


03.11.2023




- Основными показателями **сложности** алгоритма являются **затраченное время** работы и **используемая память** при работе
- Вспомним, что любой алгоритм обладает **свойством универсальности**, то есть должен подходить под несколько входных данных
- При оценке этих двух показателей важно учитывать, **насколько большие входные данные пришли на вход алгоритма**. Можно считать, что **затраченное время** и **использованная память** – это функции от размера входных данных



- Поскольку выяснили, что показатели сложности – функции (кстати, не обязательно одноместные) от размеров входных данных, **будем оценивать поведение функции на бесконечности**
- Для оценки поведения функции на бесконечности можно использовать **O-большое**
- Определение.** Пусть функции  $f(x)$  и  $g(x)$  определены на  $\mathbb{R}$ . Тогда **функцию  $f$  называют  $O(g)$** , если:
$$\exists C \in \mathbb{R} \forall x > x_0: |f(x)| \leq |Cg(x)|$$
- Функция  $Cg(x)$  выступает своего рода **асимптотой для функции  $f(x)$** , которую она не сможет превысить






Красным отмечена  $f(n) = (n - 2)^2$   
Синим отмечена  $g(n) = 3 + \log_2 n$

- **Самый простой пример:**  $3n^2 = O(n^2)$ . Можно подобрать такую константу  $C$  (например,  $C=4$ ), что  $Cn^2 > 3n^2$  для всех достаточно больших  $n$
- Кроме того, верно, например,  $n = O(n^2)$
- Возможно, запись  $O(n^2)$  **проще воспринимать не как функцию, а как класс функций  $f$** , для которых можно подобрать такую константу, что  $|f(x)| \leq |Cn^2|$
- Отметим, что  $f(n) = (n - 2)^2 \neq O(3 + \log n)$
- При этом,  $g(n) = 3 + \log_2 n = O((n - 2)^2) = O(n^2)$



- Для сравнения приведена часть самых популярных классов функций для оценок сложности алгоритмов
- Одним из самых «медленных» классов является  $O(n^n)$ , он характеризует алгоритмы, использующие полный перебор возможных вариантов решения
- $n!$  можно оценить как  $O((n/e)^{(n+1/2)})$  по следствию из формулы Стирлинга







- Представим, что в памяти лежит некоторый массив, хотим **обратиться к первому элементу**. Какова **сложность такой операции по времени**?
- Теперь хотим **посчитать сумму** элементов в этом массиве. Какова сложность у этого алгоритма?
- А если в массиве записаны **подряд идущие натуральные числа**, причем мы знаем их количество?
- Верно ли, что  $100000n = O(n^2)$ ?
- Верно ли, что  $O(\log_3 n^2) = O(\log_2 n^3)$ ?



- Представим, что в памяти лежит некоторый массив, хотим **обратиться к первому элементу**. Какова **сложность такой операции по времени**?  $O(1)$
- Теперь хотим **посчитать сумму** элементов в этом массиве. Какова сложность у этого алгоритма?  $O(n)$
- А если в массиве записаны **подряд идущие натуральные числа**, причем мы знаем их количество?  $O(1)$
- Верно ли, что  $100000n = O(n^2)$ ? Да
- Верно ли, что  $O(\log_3 n^2) = O(\log_2 n^3)$ ? Да






- Потренируемся оценивать сложность через  $O$ -большое на **алгоритме сортировки слиянием**
- На вход подается массив целых чисел длины  $n$ , требуется вернуть отсортированный массив
- **Алгоритм.** Разбиваем список на пары соседних чисел, сортируем числа в парах, получаем не более  $n/2$  отсортированных пар. Далее начинаем слияние: берем две соседние пары и сливаем их в список длины 4
- На  $k$ -ой стадии алгоритма будет не более  $n/2^k$  групп отсортированных чисел, которые нужно слить в  $n/2^{k+1}$  групп в 2 раза большего размера

6 5 3 1 8 7 2 4

Пример работы сортировки слиянием




- Оценим число стадий алгоритма (на которых происходит слияние групп)
- Перед первой стадией число групп равно числу элементов, потому что каждая группа состоит из одного элемента
- После каждой стадии число групп уменьшается примерно в два раза (если быть точным, из  $k$  групп образуются  $\lceil k/2 \rceil$  групп. В конце остается одна группа)
- Значит, число стадий можно оценить как  $O(\log n)$



Пример работы сортировки слиянием



- **Что происходит на каждой из стадий?** Слияние двух групп из  $k$  элементов происходит за  $4k$  шагов (если за шаг считать либо сравнение двух элементов, либо запись числа в итоговую группу размера  $2k$ )
- Суммарное количество элементов в группах равно  $n$  для любой стадии, значит, **число шагов на каждой стадии можно оценить как  $2n$**
- Итого: на каждой из  $O(\log n)$  стадий происходит порядка  $O(n)$  шагов. Значит, **временная сложность алгоритма –  $O(n \log n)$**




Пример работы сортировки слиянием



- **Какую оценку можно дать по требуемой памяти?** Учитывая, что входной массив надо постоянно где-то хранить, то **минимальная оценка** –  $O(n)$
- При этом, можно показать, что **оценка сверху аналогичная**: можно хранить текущее состояние массива после очередной стадии в одном массиве, а само слияние проводить в другом
- **Сложность алгоритма по памяти** –  $O(n)$

6 5 3 1 8 7 2 4


Пример работы сортировки слиянием



Двоичное дерево


- Рассмотрим популярную структуру хранения данных – **двоичное дерево**
- Суть проста: есть множество вершин, на котором задано **отношение порядка**
- У каждой вершины есть не более одного предка, а также не более двух потомков
- Особенность: для любой вершины **левый потомок должен быть меньше, а правый – больше**





Двоичное дерево

- Кажется, что **операция вставки** работает за  $O(\log n)$
- Требуется **спуститься от корня вниз**, попутно сравнивая новое значение с потомками и выбирая левое или правое поддереву, и вставить лист (*так называют вершину без потомков*)
- **Операция поиска** работает аналогично за  $O(\log n)$



То же самое двоичное дерево

- Тогда почему мы говорим о **балансировке двоичного дерева**?
- Без балансировки после каждой операции вставки дерево может принять очень неудобный вид, который **рушит все наши предположения** о том, что операция вставки и поиска **всегда работает за  $O(\log n)$**
- В таких случаях говорят, что алгоритм работает в **худшем случае за  $O(n)$** , а в **среднем случае – за  $O(\log n)$**
- Балансировку дерева обеспечивает, например, АВЛ-дерево



- Будем решать **задачу возведения числа 2 в положительную степень двойки** (4, 8, 16 и так далее). На вход подается единственное число  $N$  — показатель степени
- Наивный алгоритм выглядит примерно так: создаем переменную, равную единице, умножаем её на 2 нужное количество раз. **Число арифметических операций равно  $N$**
- Модифицированный алгоритм выглядит так: **чтобы вычислить число  $2^{2^k}$ , можно вычислить число  $2^k$  и возвести его в квадрат**. Аналогично поступить с числом  $2^k$  и так далее, пока не дойдем до  $2^1$
- Число арифметических действий модифицированного алгоритма **уменьшилось**: оно равно  $\log_2 N$ , что меньше  $N$  для всех целых  $N > 1$

- $2^{16} = A * A$ , где  $A = 2^8$
- $2^8 = B * B$ , где  $B = 2^4$
- $2^4 = C * C$ , где  $C = 2^2$
- $2^2 = D * D$ , где  $D = 2$



10 – десять

100 – сто

1 000 – тысяча

1 000 000 – миллион

1 000 000 000 – миллиард

1 000 000 000 000 – триллион

1 000 000 000 000 000 –

квадриллион



- Оценим длину полученного числа снизу, ведь нужно куда-то его сохранить, чтобы работать с ним дальше, или просто вывести
- Заметим, что  $2^{10} = 1024$ , что чуть больше 1000. Тогда число  $2^{10 \cdot K}$  будет не меньше, чем  $1000^K$ . Число  $1000^K$  — это  $3K$  нулей и одна единица, то есть запись числа  $2^{10 \cdot K}$  не короче, чем  $3K + 1$  символ
- Тогда для входного показателя степени  $N$  **полученное число будет не короче  $3N/10 + 1$  символов**
- Для  $N = 4$  это не больше 3 символов, а вот для  $N = 1024$  **это уже минимум 307 символов**, хотя в первом случае нужно совершить 2 операции, а во втором – всего 10
- Очевидно, что процессы вывода числа длиной 3 символа и вывода числа длиной 307 символов **не могут отличаться по числу шагов всего лишь в 5 раз**

# Пример: быстрое возведение в степень



Санкт-Петербургский  
государственный  
университет

- Будем хранить большие числа, разбив их на **макродиффры**, которые помещаются в один из типов данных. Каждая макродиффра отвечает сразу за несколько соседних разрядов большого числа
- Для удобства будем использовать десятичные макродиффры, не превышающие 100. Тогда **число 1 000 034 506 будет представлено в виде 6 ячеек**: 5 макродиффр и одного счетчика макродиффр
- Чтобы вывести это число, нужно вывести каждую ее макродиффру, при необходимости дополнив запись ведущими нулями. Каждая макродиффра отвечает за фиксированное число разрядов (скажем,  $m$ ), поэтому для числа длины  $n$  нужно использовать  $O(n)$  макродиффр (не меньше  $n/m$ )
- Если считать шагом дополнение ведущими нулями и вывод макродиффры, то алгоритмическая сложность вывода большого числа равна  $O(n)$  по времени и по памяти, где  $n$  – д

$A[0]$	$A[1]$	$A[2]$	$A[3]$	$A[4]$	$A[5]$
5	6	45	3	0	10






- Следует различать вычислительную сложность алгоритма, **зависящую от длины размера входных данных**, и «**число шагов**» работы алгоритма. Это различие следует из того, что понимается под словом «шаг»
- Считая шагом любую арифметическую операцию с неограниченно большими числами, можно **неправильно оценить сложность алгоритма**
- В предыдущих алгоритмах и в дальнейшем будем считать, что **числа не очень большие**: ввод, вывод и другие арифметические операции с ними будут работать за  $O(1)$



- Главные показатели сложности алгоритма — **затраченное время и используемая память**. Эти показатели принято оценивать как **функции от размера входных данных**
- Главный инструмент в оценке алгоритмов между собой — **O-большое**. С его помощью можно утверждать, что **одни алгоритмы будут работать лучше (быстрее) других** при стремлении размера выходных данных к бесконечности
- У алгоритмов бывают **худшие, лучшие и средние случаи работы**. Природа некоторых алгоритмов такова, что оценки по времени и памяти для этих случаев могут быть **разными**
- Следует правильно выбирать определение понятия «шаг алгоритма». Оно должно **зависеть от длины входных данных**





# Сложность алгоритмов



Классы P и NP


Направление «Искусственный интеллект и наука о данных», 23.Б16-мм, 23.Б18-мм

03.11.2023

# Что за классы P и NP?




Санкт-Петербургский  
государственный  
университет



Соотношение классов P и NP при равенстве и  
неравенстве

- Есть такие сложные задачи, для которых не придумали быстрых алгоритмов. Единственный известный способ получения *точного* решения таких задач — **проверить почти все возможные варианты**
- **Класс NP** — сложные задачи, решаемые перебором
- **Класс P** — задачи, для которых известен (квази-) полиномиальный алгоритм
- **Гипотезу о равенстве классов NP и P** пока никто не смог **ни доказать, ни опровергнуть**



Дерево полного перебора, которое генерирует на лентах недетерминированная МТ

- **Название класса P** происходит от английского *polynomial*, подразумевая наличие быстрого алгоритма
- **Класс NP** происходит не от non-polynomial, а от *non-deterministic polynomial*
- Вспомним **абстрактную машину Тьюринга**: у нее была одна лента, на которой выполнялись все вычисления. Такая версия машины называется **детерминированной**
- **Недетерминированная машина** сначала генерирует все возможные варианты, выделяя каждому варианту свою ленту, а потом проверяет все ленты и ищет оптимальное решение





- Генерация всех возможных вариантов на обычной машине Тьюринга занимает **экспоненциальное время**, например,  $O(2^n)$
- **На недетерминированной машине**, которая размножает ленты в режиме реального времени, **генерация всех возможных вариантов занимает полиномиальное время**
- Поэтому и говорят, что задача из класса NP решается за полиномиальное время на недетерминированной машине Тьюринга





## РАЗБИЕНИЕ

Дано: конечное множество  $A$ ,  
для каждого  $a \in A$  его «вес»  $s(a) \in \mathbb{Z}_+$ .

Вопрос: существует ли разбиение множества  $A$  на два подмножества одинакового веса?

$$\exists A' \left( A' \subseteq A \ \& \ \sum_{a \in A'} s(a) = \sum_{a \in (A \setminus A')} s(a) \right).$$

- **Полный перебор** можно организовать следующим образом. Представим разбиение множества  $A$  как битовую полосу: 0 – если элемент входит в первое множество, 1 – если входит во второе. **Генерируем все варианты за  $O(2^n)$** , где  $n$  – мощность входного множества
- Проверка каждого разбиения составляет  $O(n)$  операций



- Некоторые задачи **не имеют быстрых алгоритмов для решения**, например, задача о разбиении. Самый быстрый алгоритм для **точного** решения подобных задач – полный перебор
- Для **гипотезы о равенстве классов NP и P** пока никто не смог придумать ни доказательство, ни опровержение
- Решение задачи из класса NP на **недетерминированной МТ** занимает **полиномиальное время**, а на обычной **детерминированной** — **экспоненциальное**





# Сложность алгоритмов



Направление «Искусственный интеллект и наука о данных», 23.Б16-мм, 23.Б18-мм

03.11.2023



- Дополнительные баллы за дополнительные лекции) От вас требуется проявить желание послушать хотя бы одну лекцию (**обязательно написав нам до конца дня**), зарегистрироваться в событии, послушать лекцию и составить конспект
- Всего можно получить от 5 до 10 баллов в зависимости от Вашей активности на лекции и качества конспекта
  - 07.11. Показатели оценки эффективности инновационного проекта: [ссылка](#)
  - 10.11. Оценка бизнеса: [ссылка](#)
  - 10.11. Правильный питч: [ссылка](#)
  - 23.11. Методология «Agile»: [ссылка](#)

